

6/8/2020 Capítulo 1: Princípios elementares para a análise de dados utilizando os modelos de regressão lineares (resumo)

Suposição:

$$X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$$

μ e σ^2 são desconhecidos

Propriedades:

Estimador p/ μ :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \begin{cases} \rightarrow E(\bar{X}) = \mu \\ \rightarrow \text{Var}(\bar{X}) = \sigma^2/n \end{cases}$$

Estimador p/ σ^2

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \rightarrow E(S^2) = \sigma^2$$

Um olhar detalhado p/ $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \hat{\mu}$

$$\textcircled{1} \bar{y} = \arg \min_{\mu} \sum_{i=1}^n (y_i - \mu)^2 : \frac{\partial \sum_{i=1}^n (y_i - \mu)^2}{\partial \mu} = \sum_{i=1}^n 2(y_i - \hat{\mu}) \cdot (-1) = 0$$

$$-2 \sum_{i=1}^n y_i + 2 \sum_{i=1}^n \hat{\mu} = 0$$

$$2n\hat{\mu} = +2 \sum_{i=1}^n y_i$$

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i$$

$\textcircled{2} \bar{y} = \hat{\mu}$ é o estimador de máxima verossimilhança p/ o parâmetro μ (pg. 17)

ou seja: $X_i \sim N(\mu, \sigma^2) \rightarrow \hat{\mu} = \frac{1}{n} \sum_{i=1}^n y_i$

$$F(\mu, \sigma^2) = P(X_1 = y_1, X_2 = y_2, \dots, X_n = y_n), \text{ assumindo independência:}$$

$$= P(X_1 = y_1) \times P(X_2 = y_2) \times \dots \times P(X_n = y_n)$$

$$= \prod_{i=1}^n P(X_i = y_i), \text{ sendo identicamente distribuídas...}$$